Raport z projektu indywidualnego

Vowpal Wabbit

Dawid Wietrzych i Jacek Krakowski

Vowpal Wabbit

1. Implementacja

Do zaimplementowania uczenia maszynowego w naszej symulacji użyliśmy systemu wspieranego przez firmę Microsoft jakim jest Vowpal Wabbit. Na naszych maszynach zainstalowany został cały pakiet VW, a z algorytmu może korzystać każda inna maszyna, która ma zainstalowany wyżej wymieniony pakiet.

2. Model – Input - Output

Naszymi danymi wejściowymi do uczenia był plik tekstowy wygenerowany przez funkcje get_data_for_vowpal.py, gdzie po każdym przejściu mapy przez śmieciarkę, do pliku zostały dopisywane kolejne przejścia w wymaganym przez VW formacie stringów. Do trenowania zostało użyte 5955 przykładów uczących. Każda linia składa się z tzw. „Labela" (liczby z zakresu od 0 do 4),

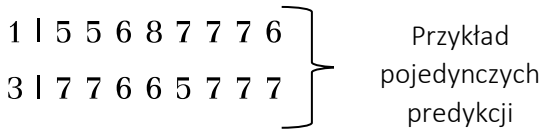

określającego w naszym przypadku przewidywany ruch dla danej sytuacji w jakiej znajduję się agent. To znaczy odpowiednio przesunięcie śmieciarki w górę („0"), w lewo („1"), w dół („2"), lub prawo („3"), a także bez ruchu (wymuszone przez strukturę naszych algorytmów przechodzenia). Do uzyskania tych wyników posłużyliśmy się algorytmami przechodzenia w głąb i wszerz (*Depth First Search i Breadth First Search*). Dzięki temu algorytm, za każdym przesunięciem się agenta sprawdzał wszystkie elementy dookoła i odpowiednio przypisywał wartości obiektom (konwertował je na format VW) tj:

- 5 - droga
- 6 – domek
- 7 – wszystko inne (m.in. trawa)

Wersja naszego modelu została wytrenowana na 15 przejściach przez dane wejściowe. Dzięki temu otrzymaliśmy plik cache, który uwydatniał pracę algorytmowi uczenia.

Zostały też użyte dodatkowe flagi to trenowania jak:

- *-c* – używanie plików cache, do szybszego działania algorytmu
- *-passes 15* – uwzględnienie liczby trenowań

Jak i już w części tworzącej model:

- *-t* – nieskupianie się na labelach, lecz na części w której znajdują się poszczególne obiekty (co pozwala zmniejszyć zużycie pamięci
- *--quiet* - wyłącza normalny wydruk diagnostyczny aktualizacji postępu.

Dance wyjściowe są swoistym przewidywaniem najlepszej drogi dla naszej śmieciarki (według algorytmów VW), tak aby odwiedziła wszystkie domy w możliwe jak najkrótszym czasie, bez konieczności powtarzania dróg (znalezienie optymalnej ścieżki Hamiltona).

3. Uruchomienie

Po uruchomieniu środowiska z modelem uczącym śmieciarka porusza się odpowiednio po wyznaczonych drogach i zatrzymuję się przy wybranych domkach. Dane wszystkich statystyk po uruchomieniu wyglądają następująco:

```
final_regressor = ../Data/vowpal.model
Num weight bits = 18
learning rate = 0.5
initial_t = 0
power_t = 0.5
decay_learning_rate = 1
using cache_file = ../Data/vowpal-data.txt.cache
ignoring text input in favor of cache input
num sources = 1
average  since         example        example  current  current  current
loss     last          counter         weight    label  predict features
1.000000 1.000000            1            1.0   1.0000   0.0000        9
3.655604 6.311208            2            2.0   4.0000   1.4878        9
3.466136 3.276669            4            4.0   1.0000   1.8501        9
3.823006 4.179875            8            8.0   4.0000   1.4175        9
3.103831 2.384656           16           16.0   2.0000   2.1663        9
2.376020 1.648209           32           32.0   1.0000   1.8924        9
2.433972 2.491925           64           64.0   3.0000   2.3930        9
1.991000 1.548027          128          128.0   0.0000   2.5055        9
1.797653 1.604307          256          256.0   2.0000   2.4506        9
1.663720 1.529787          512          512.0   4.0000   3.2069        9
1.566940 1.470159         1024         1024.0   1.0000   1.7464        9
1.543921 1.520902         2048         2048.0   4.0000   2.1040        9
1.493835 1.443749         4096         4096.0   4.0000   2.4284        9
1.459436 1.459436         8192         8192.0   3.0000   2.7216        9 h
1.474756 1.490076        16384        16384.0   1.0000   1.9235        9 h

finished run
number of examples per pass = 5360
passes used = 4
weighted example sum = 21440.000000
weighted label sum = 47164.000000
average loss = 1.455099 h
best constant = 2.199813
total feature number = 192960
```